

---

---

TRAVAUX DIRIGÉS :  
TEST D'ADÉQUATION

---

---

STATISTIQUES

QUENTIN BERGÉ  
*ENSEEIH*T



JUIN 2019

## 1 Introduction

Le sujet de cette étude est de déterminer la loi de distribution de la variable aléatoire "absence de ceinture".

## 2 Statistiques Descriptives

1. Pour construire l'histogramme des fréquences on a implanté ceci dans Matlab. On a par la même occasion ajouté les valeurs extrêmes de la variable aléatoire.

```
% Figure 1
bar(Xemp, femp, 'w')
hold on
plot(minX, femp(minXi), 'x', maxX, femp(minXi), 'o',
      Xemp(modfi), modfi, 'd') %plot des max et min
                             et mode
plot(Xemp, ftheo, 'r')
```

L'histogramme des fréquences paraît centré sur la moyenne et cela pourrait s'apparenter à une loi normale.




FIGURE 1 – Histogramme des fréquences

2. Afin d'obtenir les valeurs extrêmes de la v.a. on utilise les fonctions intrinsèques **min** et **max** qui nous donnent les valeurs maximale et minimale ainsi que leur indice.

```
[maxX, maxXi]=max(Xemp); %on récupère le max des
                    fréquence, ainsi que l'indice de ce max
[minX, minXi]=min(Xemp);
```

Nous utiliserons cet indice pour le tracer dans la figure. On obtient le minimum égal à 7, c'est-à-dire qu'au minimum il y a eu 7 absences de ceinture et qu'au maximum il y a eu 30 absences de ceinture de sécurité.

3. Le mode correspond à la valeur la plus fréquente de l'effectif empirique. Pour la trouver nous utilisons encore une fois la valeur maximale sur la fréquence empirique cette fois-ci.

```
%Pour le mode c'est la valeur la plus fréquente
=> max de f
[modef, modofi]=max(femp);
```

On obtient le mode égal à 0.1, or  $0.1 \times 300 = 30$ , l'effectif associé est 19, c'est-à-dire que durant 30 jours il y a eu 19 absences de ceintures, c'est le nombre d'absences de ceintures que l'on trouve le plus fréquemment. On le tracera de la même manière que précédemment dans la figure.

4. Afin de construire et de tracer l'histogramme des fréquences cumulées ou fonction de répartition empirique (CDF) de la variable aléatoire, on effectue la somme cumulative des fréquences empiriques à l'aide d'une boucle.

```
% calcul de la CDF empirique
CDF=zeros(1,n); %initialisation
CDF(1)=femp(1);
for i=2:n
    CDF(i)=CDF(i-1)+femp(i);
end
```

On le représente ensuite dans la figure suivante en implantant dans Matlab le code suivant :

```
%Figure 2
bar(Xemp,CDF)%CDF empirique en barres
hold on
plot(Xemp(di1),CDF(di1),'o',Xemp(medi),CDF(medi),
      'd',Xemp(c95i),CDF(c95i),'x')
```




FIGURE 2 – Histogramme des fréquences cumulées empiriques

5. Pour trouver les 1<sup>er</sup> décile, la médiane et le 95<sup>ème</sup> centile on va utiliser la fonction `find` qui permet de renvoyer le premier indice de la valeur mise en argument.

```
%find renvoi direct l'indice
di1=find(CDF>0.1,1);%1er décile
medi=find(CDF>0.5,1);%mediane
c95i=find(CDF>0.95,1);%95 centile
```

On trouve le 1<sup>er</sup> décile égal à 13, c'est-à-dire que 10 % des valeurs représentent 13 absences de ceintures. La médiane est de 18, cela signifie que 18 absences de ceintures partagent la série en 2 parties du même effectif. Le 95<sup>ème</sup> centile est de 25, c'est-à-dire que 95 % des valeurs représentent 25 absences de ceintures.

### 3 Choix de la Théorie et Calculs des Paramètres

1. La formule de la densité de probabilité d'une loi de poisson est :

$$\frac{\lambda^k}{k!} e^{-\lambda}$$

2. Cette loi possède un paramètre qui est  $\lambda$
3. Calculons l'espérance mathématique de la loi de Poisson :

$$E(x) = \sum_{k=0}^{+\infty} k \frac{\lambda^k}{k!} e^{-\lambda}$$

Or puisque pour  $p(0) = P(X = 0) = 0 \times \frac{\lambda^0}{0!} e^{-\lambda} = 0$ , on peut commencer la somme à 1, Ainsi

$$\begin{aligned} E(x) &= \sum_{k=1}^{+\infty} k \frac{\lambda^k}{k!} e^{-\lambda} \\ &= \sum_{k=1}^{+\infty} \frac{k \lambda^k}{k!} e^{-\lambda} \\ &= \sum_{k=1}^{+\infty} \frac{\lambda^k}{(k-1)!} e^{-\lambda} \\ &= \sum_{k=1}^{+\infty} \frac{\lambda * \lambda^{k-1}}{(k-1)!} e^{-\lambda} \end{aligned}$$

Posons  $y = k - 1 \Leftrightarrow k = y + 1$ , Ainsi il vient

$$\begin{aligned} E(x) &= \sum_{y=0}^{+\infty} \frac{\lambda * \lambda^y}{y!} e^{-\lambda} \\ &= \lambda * \sum_{y=0}^{+\infty} \frac{\lambda^y}{y!} e^{-\lambda} \\ &= \lambda \end{aligned}$$

On a bien  $E(x) = \lambda$

4. Afin de calculer la moyenne empirique de la variable aléatoire on utilise la formule suivante que l'on a implanté sur Matlab :

```
moy=sum(Xemp.*femp);
```

On trouve alors une moyenne de 17.9033, en moyenne il y a donc eu 17.9 absences de ceintures.

5. Pour calculer ces paramètres on va utiliser la méthode des moments.  
On calcule le premier moment de la loi probabilités :

$$m_1 = E(x) = f(\theta)$$

On calcule alors l'équivalent empirique

$$\bar{x} = \frac{1}{n} \sum_x^{+\infty} x_i = m_1$$

On égalise les deux

$$f(\theta) = E(x) = m_1$$

D'où  $\lambda = m_1 = 17.9033$ .

## 4 Calcul de la Statistique et Conclusion

1. On peut calculer alors le  $\lambda$

```
lambda=sum(Xemp.*femp);
```

Cela nous aidera à construire les fréquences théoriques à l'aide de la loi de poisson et l'effectif théorique :

```
%Calcul de la fréquence theorique
ftheo=zeros(1,n);
for i=1:n
    ftheo(i)=lambda^Xemp(i)*exp(-lambda)/
    factorial(Xemp(i));
end

%Calcul de l'effectif théorique
tk=zeros(1,n);
tk=300.*ftheo;
```

x	effectif empirique	fréquence théorique	effectif théorique
7	1	1,96E-03	0,589
8	2	4,39E-03	1,318
9	2	8,74E-03	2,621
10	7	1,56E-02	4,692
11	6	2,55E-02	7,637
12	14	3,80E-02	11,394
13	14	5,23E-02	15,691
14	20	6,69E-02	20,066
15	27	7,98E-02	23,950
16	22	8,93E-02	26,799
17	23	9,41E-02	28,223
18	27	9,36E-02	28,072
19	30	8,82E-02	26,452
20	26	7,89E-02	23,679
21	18	6,73E-02	20,187
22	15	5,48E-02	16,428
23	17	4,26E-02	12,788
24	12	3,18E-02	9,539
25	6	2,28E-02	6,831
26	3	1,57E-02	4,704
27	3	1,04E-02	3,119
28	2	6,65E-03	1,994
29	2	4,10E-03	1,231
30	1	2,45E-03	0,735
Total	300	0,996	298,740

TABLE 1 – Tableau rassemblant l’effectif empirique, les fréquences théoriques, ainsi que l’effectif théorique

2. Pour calculer le nombre d’intervalles on va calculer la longueur de l’effectif théorique :

```
nb_intvl = length(tk);
```

On a ici 24 intervalles ce qui est bien supérieur à 8.

3. Afin de trouver si l’effectif est assez important, il faudrait au moins que 80 % des valeurs soient supérieures à 5.

Pour cela on va encore une fois utiliser la fonction **find** comme ceci :

```
tk_5=find(tk>5);
int_80=length(tk_5)/length(tk);
```

Dans ce cas on obtient que les valeurs supérieures à 5 représentent 62.5 % des valeurs totales, ce qui est inférieur à 80 %, donc l’effectif théorique n’est pas assez important dans les intervalles.



4. On veut enfin évaluer l'intégrale de la densité de probabilité sur son support. On réalise pour cela la somme des fréquences théoriques.

```
int_ddp=sum(ftheo);
```

On trouve ici que l'intégrale de la densité de probabilité est égale à 0.9958 ce qui est différent de 1.

De plus, en souhaitant vérifier l'effectif théorique des observations :

```
tk_tot = sum(tk);
```

On trouve alors `tk_tot` égal à 298.7396 au lieu de 300.

On conclut donc qu'il doit nous manquer des valeurs.

5. On regroupe alors pour parer le problème des valeurs extrêmes.

x	effectif empirique	fréquence théorique	effectif théorique
inf. ou égal à 9	5	0.0162	4.8617
10	7	0.0156	4.6922
11	6	0.0255	7.6369
12	14	0.0380	11.3939
13	14	0.0523	15.6914
14	20	0.0669	20.0664
15	27	0.0798	23.9503
16	22	0.0893	26.7994
17	23	0.0941	28.2235
18	27	0.0936	28.0719
19	30	0.0882	26.4516
20	26	0.0789	23.6786
21	18	0.0673	20.1869
22	15	0.0548	16.4279
23	17	0.0426	12.7876
24	12	0.0318	9.5392
25	6	0.0228	6.8313
26	3	0.0157	4.7040
27 et +	8	0.0267	8.0054
Total	300	1	300.000

TABLE 2 – Tableau rassemblant l'effectif empirique, les fréquences théoriques, ainsi que l'effectif théorique regroupé

Pour calculer les fréquences théoriques empiriques on va utiliser les calculs suivants :

```
%Calcul de la fréquence theorique apres
    regroupement "fttheo_reg"
fttheo_reg=zeros(length(X_reg),1);%initialisation

%Boucle pour remplir la 1ère valeur
for i=0:9
    fttheo_reg(1)=lambda^i * exp(-lambda)/
        factorial(i)+fttheo_reg(1);
end

%Boucle pour remplir les valeurs du milieu
for i=2:19-1
    fttheo_reg(i)=lambda^X_reg(i) * exp(-lambda)/
        factorial(X_reg(i));
end

%Pour remplir la 19ème valeur on prend la ddp=1
    moins les autres valeurs
fttheo_reg(19) = 1-sum(fttheo_reg);
```

Ensuite on s'assure que la densité de probabilité après regroupement est égale à 1 :

```
%somme des fréquences théoriques
    ddp_reg = sum(fttheo_reg);
```

On va aussi calculer l'effectif théorique après regroupement

```
tk_reg = 300.*fttheo_reg;
n_reg =sum(tk_reg);
```

On va s'assurer que l'effectif théorique regroupé est assez important dans les intervalles. Pour cela il faut au moins que 80 % des **tk** soit supérieur à 5.

```
tk_5_reg=find(tk_reg>=5);
inf_5_reg=length(tk_5_reg)/length(tk_reg);
```

On trouve 84.211 %.

6. On peut alors tracer les fréquences théoriques et empiriques selon le code suivant :

```
%Figure 3
bar(X_reg,femp_reg,'w')
plot(X_reg,ftheo_reg)
```

Ce qui donne ceci :




FIGURE 3 – Histogramme des fréquences du regroupement

On va pouvoir alors confronter les distributions empiriques et théoriques dans un diagramme de fréquences.

Pour ceci on va calculer la fonction de répartition empirique des observations regroupées :

```
CDFemp_reg=zeros(length(X_reg),1);  
CDFemp_reg(1)=1/n_theo_reg;  
for i=2:19  
    CDFemp_reg(i)=sum(femp_reg(1:i));  
end
```

On va aussi calculer la fonction de répartition de la loi de Poisson regroupée :

```
CDFtheo_reg=zeros(length(X_reg),1);  
CDFtheo_reg(1)=1/n_theo_reg;  
for i=2:19  
    CDFtheo_reg(i)=sum(fttheo_reg(1:i));  
end
```

On pourra alors les tracer dans la figure 4

```
%Figure 4  
bar(X_reg,CDFemp_reg,'w')  
plot(X_reg,CDFtheo_reg,'b')
```




FIGURE 4 – Histogramme des fréquences du regroupement

7. Pour comparer les écarts entre les distributions empiriques et théoriques on va calculer le  $\chi^2$  selon la formule suivante :

$$\chi^2 = \sum_{k=1}^{k=n} \frac{(\theta_k - T_k)^2}{T_k}$$

que nous traduirons dans Matlab par le code suivant :

```
chi2 = sum((femp_reg.* n_theo_reg -  
tk_reg).^2 ./ tk_reg )
```

Cela nous donnera  $\chi^2 = 8.3295$

8. Si on fixe un risque  $\alpha = 0.05$ , et que l'on a pour le calcul de degrés de liberté :

$$ddl = k - r - 1$$

avec  $r$  qui est le paramètre ici égal à 1 et  $k$  égal à 19 cela nous donne donc 17 degrés de liberté. Pour 17 degrés de liberté et un risque  $\alpha$  on trouve un seuil de 27.857 dans la table du  $\chi^2$ .

Étant donné que le  $\chi^2 < seuil$ , on peut approuver l'hypothèse  $H_0$  selon laquelle la loi de Poisson est une bonne loi théorique pour représenter le problème avec un risque de 5 % de se tromper.

9. Avec le même nombre de degrés de liberté c'est-à-dire 17, on peut alors monter jusqu'à 95 % de risque.